

Atividade 3

Tabu Search para o MAX-SC-QBF

MO824 - Tópicos em Otimização Combinatória - Unicamp

Carlos E. Cavalieri Furtado
RA 219748
c219748@dac.unicamp.br

Luiz Fernando Lima Leite
RA 248405
l248405@dac.unicamp.br

Felipe Araújo de Lima
RA 29021
f290210@g.unicamp.br

I. INTRODUÇÃO

Este relatório apresenta a implementação do Tabu Search (TS) para o problema de maximização de função binária quadrática com restrições de cobertura de conjuntos (MAX-SC-QBF), desenvolvido para a disciplina MO824. O trabalho consiste na implementação do algoritmo base [1]. Adicionalmente, são avaliados impactos de ajuste de hiperparâmetros (tenure), estratégias de busca (*First-improving* e *Best-improving*) e estratégias alternativas de construção (*Intensification by Restart* e *Diversification by Restart*).

O relatório está estruturado em seis seções: (1) esta introdução; (2) definição formal do problema MAX-SC-QBF e sua formulação matemática como um problema de Programação Linear Inteira; (3) metodologia empregada, incluindo instâncias, implementação e ambiente computacional; (4) resultados experimentais com análise comparativa de desempenho, tempo de execução e melhoria em relação ao PLI da Atividade 1 e ao GRASP da atividade 2; (5) conclusões sobre o comportamento do modelo em diferentes configurações; e (6) referências bibliográficas utilizadas.

As tarefas foram divididas da seguinte forma entre o grupo:

- Felipe: Responsável pela implementação do Tabu Search padrão, incluindo toda a lógica de vizinhança, lista tabu e critérios de parada. Implementou também as variações de tenure (T1 e T2) e as estratégias de busca *First-improving* e *Best-improving*;
- Carlos: Conduziu a implementação da estratégia alternativa 1 (*Intensification by Restart*), adaptando o código para reinicialização periódica e controlando a limpeza da lista tabu. Foi o principal responsável pela execução sistemática dos experimentos, coleta de métricas (melhor solução, tempo, iterações) e organização dos arquivos de resultados. Além disso, elaborou a estrutura do relatório;
- Luiz: Desenvolveu a estratégia alternativa 2 (*Diversification by Restart*), criando o mecanismo de memória de frequência e a rotina para inserção forçada de subconjuntos pouco explorados. Além disso, redigiu a metodologia do método implementado;

Além disso, todos os alunos participaram da discussão dos resultados e conclusão do trabalho.

II. O PROBLEMA MAX-QBF COM SET COVER

A. Definição do Problema

No problema MAX-SC-QBF, desejamos maximizar uma função binária quadrática (QBF) sujeita a restrições de cobertura de conjuntos, onde o universo a ser coberto é o próprio conjunto de variáveis da QBF. Uma QBF é uma função $f : \mathbb{B}^n \rightarrow \mathbb{R}$ que pode ser expressa como uma soma de termos quadráticos:

$$f(x_1, \dots, x_n) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} \cdot x_i \cdot x_j \quad (1)$$

onde $a_{ij} \in \mathbb{R}$, $(i, j = 1, \dots, n)$ são os coeficientes da função f . Logo, o problema de maximização da QBF pode ser expresso como $Z = \max f(x)$

Para o caso especial com restrições de cobertura de conjuntos, definimos $N = \{1, \dots, n\}$ como o *conjunto de variáveis* da QBF. Seja $S = \{S_1, \dots, S_m\}$ uma coleção de subconjuntos $S_i \subseteq N$, representando as variáveis que o subconjunto i cobre. Cada subconjunto i está associado a uma variável binária x_i indicando sua seleção. Para cada par (i, j) de subconjuntos, temos um coeficiente $a_{ij} \in \mathbb{R}$ que representa o ganho (positivo ou negativo) por selecionar ambos simultaneamente.

Nosso objetivo é selecionar subconjuntos de forma que:

- todas as variáveis da QBF sejam cobertas, ou seja, para todo $k \in N$, exista ao menos um S_i tal que $k \in S_i$ e $x_i = 1$;
- seja maximizado o ganho quadrático total derivado das interações entre subconjuntos selecionados.

B. Formulação Matemática

Para formular o problema como um PLI, vamos primeiramente linearizar a função objetivo 1, introduzindo a variável

$$y_{ij} = \begin{cases} 1 & \text{se } x_i \text{ e } x_j \text{ são selecionados} \\ 0 & \text{caso contrário} \end{cases}$$

Dessa forma, a nova função objetivo é dada por:

$$\max \sum_{i=1}^n \sum_{j=1}^n a_{ij} \cdot y_{ij} \quad (2)$$

Em seguida, vamos definir as restrições que garantem que para determinado conjunto $(i, j = 1, \dots, n)$, $y_{i,j} = 1$ se e somente se $x_i = 1$ e $x_j = 1$:

$$y_{ij} \leq x_i \quad (3)$$

$$y_{ij} \leq x_j \quad (4)$$

$$y_{ij} \geq x_i + x_j - 1 \quad (5)$$

Por fim, adicionamos também as restrições que garantem que todas as variáveis da QBF sejam cobertas por pelo menos um subconjunto:

$$\sum_{i:k \in S_i} x_i \geq 1 \quad \forall k \in N \quad (6)$$

III. METODOLOGIA

A. Instâncias

Para avaliar o desempenho das abordagens propostas em diferentes cenários, foram implementados três padrões distintos de geração de subconjuntos, combinados com cinco tamanhos de instância ($n \in \{25, 50, 100, 200, 400\}$), totalizando 15 instâncias de teste.

Padrão 1 - Subconjuntos Pequenos: Cada subconjunto S_i contém entre 2 e 4 elementos, iniciando sempre com o elemento i para garantir cobertura, complementado por elementos aleatórios. Este padrão gera alta fragmentação com muitas variáveis binárias, simulando problemas com opções de cobertura limitada.

Padrão 2 - Estrutura de Vizinhança: Os subconjuntos são formados por elementos consecutivos em estrutura circular, com tamanhos variando entre $n/10$ e $n/5$. Por exemplo, S_i pode conter $\{i, i+1, i+2, \dots\} \bmod n$. Este padrão simula problemas com localidade espacial ou temporal, onde elementos próximos tendem a ser cobertos juntos.

Padrão 3 - Tamanhos Heterogêneos: Implementa uma distribuição mista com 30% de subconjuntos pequenos (2-3 elementos), 50% médios ($n/8$ a $n/4$ elementos) e 20% grandes ($n/3$ a $n/2$ elementos), com elementos selecionados aleatoriamente. Este padrão representa cenários mais realistas onde as opções de cobertura têm custos e capacidades variadas.

A matriz de coeficientes A é gerada com valores aleatórios uniformemente distribuídos no intervalo $[-10, 10]$, armazenada em formato triangular superior. Todas as instâncias utilizam "seeds" fixas para garantir reprodutibilidade dos experimentos.

Na demonstração de resultados, as instâncias terão nomenclatura $n[X]p[Y]$, onde X é o tamanho de instância e Y é o padrão de geração exposto acima.

B. O Tabu Search

Nesta subseção descrevemos a metaheurística Tabu Search usada no trabalho, ressaltando seu funcionamento geral, descrição da heurística construtiva, lista tabu (estrutura e atualização), critério de aspiração, operadores de busca local, métodos de busca (first-improving e best-improving), critérios de parada e estratégias tabu alternativas.

1) **Modelo padrão:** O algoritmo Tabu Search implementado segue a estrutura clássica descrita por [1]. A busca inicia com uma solução construtiva gulosa que adiciona subconjuntos até garantir a cobertura completa do universo N . Em cada iteração, o algoritmo explora a vizinhança da solução atual através de movimentos de inserção, remoção e troca de subconjuntos, respeitando a lista tabu que armazena movimentos recentemente executados. O critério de aspiração permite aceitar movimentos tabu quando estes levam a uma solução melhor que a incumbente. A busca prossegue até atingir um dos critérios de parada estabelecidos.

2) **Tenure:** O parâmetro tenure define o número de iterações durante as quais um movimento permanece na lista tabu, impedindo sua reversão imediata. Foram avaliados dois valores de tenure: $T1 = 10$ e $T2 = 20$. Um tenure menor permite maior flexibilidade na exploração do espaço de busca, mas pode levar a ciclagem em ótimos locais. Por outro lado, um tenure maior força a diversificação, porém pode restringir excessivamente os movimentos disponíveis em instâncias menores. A escolha do tenure apropriado depende do tamanho da instância e da densidade da vizinhança explorada.

3) **Estratégias de busca:** A busca local explora uma vizinhança a partir da solução construída até não existir melhoria. Duas estratégias de busca na vizinhança serão consideradas:

- First-improving (FI): percorre vizinhos escolhidos aleatoriamente e aceita o primeiro que melhora a solução atual.
- Best-improving (BI): avalia todos os vizinhos e escolhe o melhor dentre eles em cada passo.

Ambas as estratégias serão implementadas e comparadas experimentalmente. O Tabu usa por padrão a estratégia de First-improving.

4) **Estratégias alternativas de Tabu:** Além da construção padrão descrita acima, neste trabalho serão implementadas e comparadas duas estratégias alternativas de Tabu:

- **Intensification by Restart (IbR):** Esta estratégia reinicia periodicamente a busca a partir da melhor solução encontrada, limpando a lista tabu e realizando uma busca local intensiva por 20 iterações. O objetivo é explorar mais profundamente regiões promissoras do espaço de busca. Quando ativada a cada 30 iterações, a intensificação foca em melhorar a qualidade da solução incumbente através de uma exploração exaustiva de sua vizinhança imediata, sem as restrições impostas pela lista tabu acumulada.
- **Diversification by Restart (DbR):** Quando o algoritmo não encontra movimentos que melhorem a solução, a rotina de diversificação é acionada. A cada chamada, o método seleciona aleatoriamente uma fração fixa da instância total (20%). Essa fração é composta pelos subconjuntos menos frequentes segundo a memória de frequência. Em seguida, verifica-se quais desses subconjuntos estão presentes na solução atual (ou na melhor já encontrada) e eles são mantidos na nova solução. O restante da solução é então preenchido aleatoriamente,

onde cada subconjunto remanescente tem 50% de chance de ser incluído.

5) **Cr terios de parada:** Adotaremos como cr terios de parada as seguintes condi  es:

- Tempo limite por experimento: 30 minutos;
- N mero m ximo de itera  es: 1000 itera  es;
- N mero m ximo de itera  es sem melhoria: 100 itera  es.

C. Implementa  o e Execu  o

Ambiente de Desenvolvimento: O modelo matem tico proposto e as metaheur sticas foram implementadas em Java, utilizando o framework fornecido pelos docentes da disciplina. O IDE Eclipse foi escolhido para desenvolvimento.

Especifica  es Computacionais: Os experimentos foram executados com recursos locais, que apresentam as seguintes especifica  es t cnicas:

- Modelo: MacBook Air (M1, 2020)
- Processador: Apple M1 (CPU de 8 n cleos)
- Mem ria RAM: 8 GB
- Sistema Operacional: macOS Sequoia 15.3.2

Disponibilidade do C digo: Todo o c digo-fonte, incluindo a implementa  o da metaheur stica e os scripts de execu  o, assim como as inst ncias utilizadas nos experimentos, est o dispon veis no reposit rio GitHub: https://github.com/felipearaujolina/atividade_3_mo824. Esta disponibiliza  o permite a reproduzibilidade completa e acesso aos arquivos gerados nos experimentos.

D. Coleta de Resultados

Para avalia  o dos resultados, as seguintes m tricas foram selecionadas:

- Melhor solu  o encontrada (MS): o melhor valor encontrado atrav s da abordagem utilizada;
- Tempo de execu  o: o tempo de execu  o at  a parada do algoritmo;
- N mero de itera  es: o n mero de itera  es executadas at  a parada do algoritmo;
- Taxa de Melhoria: raz o de melhoria em rela  o ao modelo exato desenvolvido na atividade 1 ou o GRASP na Atividade 2, calculado como $\frac{MS_{tabu} - MS_x}{MS_x}$, onde MS_x   o melhor valor encontrado no PLI ou no GRASP.

IV. RESULTADOS

A Tabela V, no Apendice 1, possui os dados completos dos experimentos. Abaixo, na Tabela I, foram selecionadas 3 inst ncias (simples, m dia e complexa) para ilustrar os resultados das abordagens individualmente.

Inst�ncia	n50p2		n200p1		n400p3	
Configura��o	MS-Tabu	T(s)	MS-Tabu	T(s)	MS-Tabu	T(s)
Tenure = 10	576.26	0.52	4916.78	84.05	11206.16	1892.84
Tenure = 20	538.17	0.34	4873.34	32.15	10539.28	2039.08
BI	604.28	0.60	4957.01	50.18	2985.54	2022.24
IbR	604.28	0.83	4957.01	43.10	7912.97	2040.74
DbR	549.94	0.14	2374.41	0.33	837.04	0.90

Tabela I: Resultados individuais de cada abordagem para 3 inst ncias

O par metro tenure demonstra impacto significativo na qualidade das solu  es. Com $tenure = 10$, observa-se melhor desempenho em inst ncias maiores (11206.16 para n400p3), enquanto $tenure = 20$ apresenta tempos reduzidos mas com piora na qualidade, como visto em n50p2 (538.17 vs 576.26). Este trade-off sugere que valores menores de tenure permitem maior flexibilidade na explora  o, que   importante para inst ncias complexas.

A estrat gia Best-Improving se destaca como a mais robusta, alcan ando consistentemente as melhores solu  es nas inst ncias menores e m dias. Em n50p2 e n200p1, BI atinge os valores relativamente bons (604.28 e 4957.01 respectivamente), confirmando sua efic cia em balancear qualidade e tempo computacional.

As estrat gias de reinicializa  o apresentam comportamentos distintos: IbR mant m boa qualidade com tempo de execu  o moderado, enquanto DbR demonstra tempos extremamente baixos mas com alta piora na qualidade das solu  es. Em n200p1, DbR obt m apenas 2374.41 em 0.33s, indicando converg ncia prematura devido   diversifica  o excessiva.

Na tabela II s o apresentados os resultados de diversas combina  es feitas entre as abordagens.

Inst�ncia	n50p2		n200p1		n400p3	
Configura��o	MS-Tabu	T(s)	MS-Tabu	T(s)	MS-Tabu	T(s)
IbR+Tenure = 20	604.28	1.36	4961.22	65.13	8083.80	2730.21
DbR+Tenure = 20	555.55	0.21	2408.22	1.76	913.50	2.64
DbR+BI	556.20	0.55	4907.09	47.49	2412.41	1961.71
IbR+BI	604.28	0.99	4957.01	63.67	1942.46	2268.11

Tabela II: Resultados individuais de cada abordagem para 3 inst ncias

A combina  o IbR+Tenure=20 se destaca como a configura  o mais promissora para inst ncias pequenas e m dias, alcan ando a solu  o  tima em n50p2 (604.28) e boa solu  o em n200p1 (4961.22). Esta combina  o aproveita a intensifica  o per dica com um tenure mais restritivo, equilibrando explora  o local profunda com preven  o efetiva de ciclagem.

DbR combinado com outras estrat gias continua apresentando piora significativa, confirmando que a diversifica  o agressiva prejudica a converg ncia mesmo quando combinada com mecanismos de intensifica  o. A exce  o   DbR+BI em n200p1, que atinge 4907.09, sugerindo que a busca Best-Improving pode parcialmente compensar a aleatoriedade excessiva.

A combina  o IbR+BI demonstra desempenho robusto, particularmente em n50p2 onde atinge o  timo (604.28). No entanto, para inst ncias grandes como n400p3, o desempenho piora significativamente (1942.46), indicando que a complexidade computacional desta combina  o se torna proibitiva em escalas maiores.

Por fim, apresentamos na Tabela (III) o melhor resultado por inst ncia (ranking por maior MS_{Tabu} , menor tempo e menor n mero de itera  es, nessa ordem), com a taxa de melhoria em rela  o aos resultados obtidos com o modelo exato na Atividade 1, al m dos valores obtidos no GRASP da Atividade

2 (no Apêndice 2 é possível encontrar uma versão da tabela aumentada).

Instância	Configuração	Tabu		PLI			GRASP		
		MS (Tabu)	T(s)	MS (PLI)	T(s)	Melhoria	MS (GRASP)	T(s)	Melhoria
n25p1	DnR	130.23	0.02	130.23	0.04	0.00%	130.23	0.03	0.00%
n25p2	BI	295.03	0.02	295.03	0.04	0.00%	295.03	0.04	0.00%
n25p3	BI	219.29	0.04	219.29	0.11	0.00%	219.29	0.05	0.00%
n50p1	BI	695.30	0.23	695.30	1.60	0.00%	695.30	0.24	0.00%
n50p2	BI	604.28	0.60	604.28	9.96	0.00%	604.28	0.44	0.00%
n50p3	BI	519.60	0.74	519.60	12.37	0.00%	519.60	0.49	0.00%
n100p1	DnR+BI	1299.90	8.84	1291.90	600.02	0.62%	1299.90	2.06	0.00%
n100p2	IbR+BI	1818.50	18.68	1818.50	600.03	0.00%	1818.50	5.18	0.00%
n100p3	IbR+Tenure=20	1705.63	17.76	1699.02	600.03	0.39%	1707.06	6.26	-0.08%
n200p1	IbR+Tenure=20	4961.22	65.13	4945.25	600.07	0.32%	4961.22	19.40	0.00%
n200p2	IbR+Tenure=20	4663.40	178.70	4429.10	600.08	5.29%	4669.34	104.50	-0.13%
n200p3	IbR	4919.73	272.95	4715.38	600.08	4.33%	4957.67	176.96	-0.77%
n400p1	IbR+Tenure=20	10478.36	1500.26	9305.59	600.18	12.60%	10488.00	359.83	-0.09%
n400p2	IbR+Tenure=20	13085.76	1805.02	6248.32	600.25	109.43%	13108.48	1802.27	-0.17%
n400p3	Tenure=10	11206.16	1892.84	6179.49	600.25	81.34%	12869.30	1800.77	-12.92%

Tabela III: Abordagens vencedoras vs. modelo exato e GRASP para cada instância

A comparação com os métodos exatos revela três comportamentos distintos conforme a escala do problema. Para instâncias pequenas (n25-n50), o Tabu Search consistentemente encontra soluções ótimas, validando a qualidade da implementação. Interessantemente, diferentes configurações alcançam o ótimo nestas instâncias, sugerindo que o problema é relativamente fácil para a metaheurística.

Em instâncias médias (n100-n200), o Tabu apresenta desempenho misto. Enquanto mantém boas soluções em alguns casos (n100p2, n200p1), observa-se pequena piora em outros. Particularmente interessante é n200p2, onde IbR+Tenure=20 obtém 4663.40, representando melhoria de 5.29% sobre o PLI mas piora de 0.13% em relação ao GRASP, indicando que diferentes metaheurísticas exploram regiões distintas do espaço de busca.

Para instâncias grandes (n400), o Tabu demonstra superioridade sobre o PLI (melhorias de até 109.43% em n400p2), mas apresenta piora significativa comparado ao GRASP, especialmente em n400p3 (-12.92%). Isso sugere que, embora o Tabu seja eficaz para escapar de ótimos locais onde o PLI fica preso devido ao limite de tempo (ou que ficaria preso mesmo com limite muito superior), o GRASP com sua construção aleatorizada adaptativa explora mais eficientemente o espaço de soluções em instâncias de grande escala para o MAX-SC-QBF.

V. CONCLUSÃO

Este trabalho implementou e avaliou o Tabu Search para o problema MAX-SC-QBF, demonstrando sua eficácia em diferentes escalas. A configuração IbR+Tenure=20 destacou-se como a mais robusta, oferecendo o melhor equilíbrio entre qualidade e eficiência computacional. Os resultados evidenciam a importância crítica do parâmetro tenure e da estratégia de busca local, com Best-Improving superando consistentemente First-Improving, contrariando expectativas da literatura que sugere vantagens do FI em velocidade. Isso pode indicar uma implementação incorreta das estratégias de busca ou então uma particularidade da estrutura do problema tratado.

Comparando abordagens, o Tabu Search se destaca em instâncias médias e na melhoria sobre soluções do PLI, enquanto GRASP demonstra superioridade em instâncias grandes devido à sua construção aleatorizada adaptativa.

REFERÊNCIAS

- [1] Gendreau, M. and Potvin, J.-Y. (2010) “Tabu Search.” In: Gendreau, M. and Potvin, J.-Y. (eds.) *Handbook of Metaheuristics*. International Series in Operations Research and Management Science, vol. 146. Springer. Available: https://doi.org/10.1007/978-1-4419-1665-5_10

1. APÊNDICE

Configuration	Instance	BestValue	ExecutionTime(s)	Iterations	StoppingCriteria
DIVERSIFICATION+BEST	n25p1	130.23	0.03	107	NO_IMPROVEMENT
INTENSIFICATION+BEST	n25p1	130.23	0.03	133	NO_IMPROVEMENT
STANDARD	n25p1	130.23	0.04	112	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n25p1	130.23	0.05	108	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n25p1	124.38	0.01	112	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n25p1	113.39	0.03	133	NO_IMPROVEMENT
STANDARD+TENURE	n25p1	70.55	0.02	108	NO_IMPROVEMENT
STANDARD+BEST	n25p2	295.03	0.02	110	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n25p2	295.03	0.02	111	NO_IMPROVEMENT
INTENSIFICATION+BEST	n25p2	295.03	0.06	112	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n25p2	295.03	0.07	163	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n25p2	295.03	0.07	193	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n25p2	265.52	0.02	115	NO_IMPROVEMENT
STANDARD+TENURE	n25p2	231.27	0.02	109	NO_IMPROVEMENT
STANDARD	n25p2	217.31	0.02	120	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n25p2	206.78	0.01	109	NO_IMPROVEMENT
STANDARD+BEST	n25p3	219.29	0.04	111	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n25p3	219.29	0.05	164	NO_IMPROVEMENT
INTENSIFICATION+BEST	n25p3	219.29	0.07	110	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n25p3	219.29	0.08	163	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n25p3	219.29	0.09	163	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n25p3	177.96	0.03	111	NO_IMPROVEMENT
STANDARD+TENURE	n25p3	171.90	0.01	114	NO_IMPROVEMENT
STANDARD	n25p3	159.49	0.03	121	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n25p3	116.14	0.01	113	NO_IMPROVEMENT
STANDARD+BEST	n50p1	695.30	0.23	117	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n50p1	695.30	0.29	164	NO_IMPROVEMENT
INTENSIFICATION+BEST	n50p1	695.30	0.36	116	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n50p1	695.30	0.56	193	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n50p1	690.12	0.43	163	NO_IMPROVEMENT
STANDARD	n50p1	674.26	0.20	135	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n50p1	670.10	0.14	130	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n50p1	627.38	0.09	142	NO_IMPROVEMENT
STANDARD+TENURE	n50p1	530.25	0.12	131	NO_IMPROVEMENT
STANDARD+BEST	n50p2	604.28	0.60	124	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n50p2	604.28	0.83	135	NO_IMPROVEMENT
INTENSIFICATION+BEST	n50p2	604.28	0.99	133	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n50p2	604.28	1.36	193	NO_IMPROVEMENT
STANDARD	n50p2	576.26	0.52	156	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n50p2	556.20	0.55	127	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n50p2	555.55	0.21	348	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n50p2	549.94	0.14	402	NO_IMPROVEMENT
STANDARD+TENURE	n50p2	538.17	0.34	145	NO_IMPROVEMENT
STANDARD+BEST	n50p3	519.60	0.74	121	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n50p3	519.60	1.30	163	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n50p3	505.78	0.95	176	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n50p3	500.33	1.57	193	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n50p3	497.87	0.48	239	NO_IMPROVEMENT
STANDARD	n50p3	477.51	0.86	139	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n50p3	427.70	0.25	177	NO_IMPROVEMENT
INTENSIFICATION+BEST	n50p3	402.58	0.89	113	NO_IMPROVEMENT
STANDARD+TENURE	n50p3	359.13	0.31	134	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n100p1	1299.90	8.64	224	NO_IMPROVEMENT
INTENSIFICATION+BEST	n100p1	1285.31	8.83	133	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n100p1	1279.67	3.31	294	NO_IMPROVEMENT
STANDARD	n100p1	1253.85	5.51	176	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n100p1	1246.67	2.69	302	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n100p1	1230.66	11.79	223	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n100p1	1222.47	7.25	163	NO_IMPROVEMENT
STANDARD+BEST	n100p1	1220.64	5.69	128	NO_IMPROVEMENT
STANDARD+TENURE	n100p1	1196.74	3.57	161	NO_IMPROVEMENT
INTENSIFICATION+BEST	n100p2	1818.50	18.68	144	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n100p2	1801.39	20.22	223	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n100p2	1801.39	20.56	223	NO_IMPROVEMENT
STANDARD	n100p2	1776.92	12.07	226	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n100p2	1769.13	10.51	152	NO_IMPROVEMENT

Tabela IV: Resultados completos para cada abordagem e combinação

Configuration	Instance	BestValue	ExecutionTime(s)	Iterations	StoppingCriteria
STANDARD+DIVERSIFICATION	n25p1	130.23	0.02	209	NO_IMPROVEMENT
STANDARD+BEST	n25p1	130.23	0.03	110	NO_IMPROVEMENT
STANDARD+TENURE	n100p2	1748.11	10.58	237	NO_IMPROVEMENT
STANDARD+BEST	n100p2	1585.95	15.46	155	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n100p2	928.38	0.40	302	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n100p2	850.49	0.27	202	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n100p3	1705.63	17.76	193	NO_IMPROVEMENT
INTENSIFICATION+BEST	n100p3	1684.31	19.63	137	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n100p3	1677.23	15.86	202	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n100p3	1664.33	21.41	223	NO_IMPROVEMENT
STANDARD+TENURE	n100p3	1661.69	9.97	243	NO_IMPROVEMENT
STANDARD	n100p3	1652.82	12.74	238	NO_IMPROVEMENT
STANDARD+BEST	n100p3	1630.50	16.34	157	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n100p3	804.89	0.26	202	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n100p3	752.54	0.22	152	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n200p1	4961.22	65.13	253	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n200p1	4957.01	43.10	223	NO_IMPROVEMENT
STANDARD+BEST	n200p1	4957.01	50.18	166	NO_IMPROVEMENT
INTENSIFICATION+BEST	n200p1	4957.01	63.67	163	NO_IMPROVEMENT
STANDARD	n200p1	4916.78	84.05	288	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n200p1	4907.09	47.49	252	NO_IMPROVEMENT
STANDARD+TENURE	n200p1	4873.34	32.15	255	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n200p1	2408.22	1.76	452	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n200p1	2374.41	0.33	152	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n200p2	4663.40	178.70	343	NO_IMPROVEMENT
STANDARD	n200p2	4608.94	113.17	390	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n200p2	4607.74	158.87	313	NO_IMPROVEMENT
STANDARD+BEST	n200p2	4513.24	156.12	215	NO_IMPROVEMENT
INTENSIFICATION+BEST	n200p2	4509.10	184.28	189	NO_IMPROVEMENT
STANDARD+TENURE	n200p2	4505.44	103.79	423	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n200p2	2626.23	43.03	152	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n200p2	1073.95	0.37	152	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n200p2	1064.26	0.75	252	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n200p3	4919.73	272.95	343	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n200p3	4888.29	267.90	343	NO_IMPROVEMENT
INTENSIFICATION+BEST	n200p3	4879.60	272.48	193	NO_IMPROVEMENT
STANDARD+BEST	n200p3	4873.90	265.11	246	NO_IMPROVEMENT
STANDARD	n200p3	4862.56	166.44	395	NO_IMPROVEMENT
STANDARD+TENURE	n200p3	4849.92	155.72	392	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n200p3	2862.85	99.76	302	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n200p3	1142.14	0.24	202	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n200p3	1119.30	0.60	202	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n400p1	10478.36	1500.26	403	NO_IMPROVEMENT
STANDARD+INTENSIFICATION	n400p1	10460.62	1223.14	403	NO_IMPROVEMENT
STANDARD	n400p1	10442.92	1030.84	581	NO_IMPROVEMENT
STANDARD+TENURE	n400p1	10359.68	803.34	496	NO_IMPROVEMENT
STANDARD+BEST	n400p1	10293.27	992.21	213	NO_IMPROVEMENT
INTENSIFICATION+BEST	n400p1	10189.63	1262.88	193	NO_IMPROVEMENT
DIVERSIFICATION+BEST	n400p1	8683.75	1362.84	402	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n400p1	4856.78	11.81	502	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n400p1	2826.71	2.93	202	NO_IMPROVEMENT
INTENSIFICATION+TENURE	n400p2	13085.76	1805.02	493	TIME_LIMIT
STANDARD+TENURE	n400p2	13011.11	1804.02	770	TIME_LIMIT
STANDARD+INTENSIFICATION	n400p2	12977.09	1802.69	494	TIME_LIMIT
STANDARD	n400p2	12887.38	2139.42	650	TIME_LIMIT
STANDARD+BEST	n400p2	11856.94	1804.48	195	TIME_LIMIT
INTENSIFICATION+BEST	n400p2	11138.83	1982.81	122	TIME_LIMIT
DIVERSIFICATION+BEST	n400p2	3458.45	1143.73	402	NO_IMPROVEMENT
DIVERSIFICATION+TENURE	n400p2	931.84	1.44	252	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n400p2	841.64	1.46	152	NO_IMPROVEMENT
STANDARD	n400p3	11206.16	1892.84	543	TIME_LIMIT
STANDARD+TENURE	n400p3	10539.28	2039.08	431	TIME_LIMIT
INTENSIFICATION+TENURE	n400p3	8083.80	2730.21	234	TIME_LIMIT
STANDARD+INTENSIFICATION	n400p3	7912.97	2040.74	205	TIME_LIMIT
STANDARD+BEST	n400p3	2985.54	2022.24	43	TIME_LIMIT
DIVERSIFICATION+BEST	n400p3	2412.41	1961.71	36	TIME_LIMIT
INTENSIFICATION+BEST	n400p3	1942.46	2268.11	32	TIME_LIMIT
DIVERSIFICATION+TENURE	n400p3	913.50	2.64	352	NO_IMPROVEMENT
STANDARD+DIVERSIFICATION	n400p3	837.04	0.90	152	NO_IMPROVEMENT

Tabela V: Resultados completos para cada abordagem e combinação

2. APÊNDICE

Instância	Configuração	Tabu		PLI			GRASP		
		MS_{tabu}	T(s)	MS_{PLI}	T(s)	Melhoria	MS_{GRASP}	T(s)	Melhoria
n25p1	DbR	130.23	0.02	130.23	0.04	0.00%	130.23	0.03	0.00%
n25p2	BI	295.03	0.02	295.03	0.04	0.00%	295.03	0.04	0.00%
n25p3	BI	219.29	0.04	219.29	0.11	0.00%	219.29	0.05	0.00%
n50p1	BI	695.30	0.23	695.30	1.60	0.00%	695.30	0.24	0.00%
n50p2	BI	604.28	0.60	604.28	9.96	0.00%	604.28	0.44	0.00%
n50p3	BI	519.60	0.74	519.60	12.37	0.00%	519.60	0.49	0.00%
n100p1	DbR+BI	1299.90	8.64	1291.90	600.02	0.62%	1299.90	2.06	0.00%
n100p2	IbR+BI	1818.50	18.68	1818.50	600.03	0.00%	1818.50	5.18	0.00%
n100p3	IbR+Tenure=20	1705.63	17.76	1699.02	600.03	0.39%	1707.06	6.26	-0.08%
n200p1	IbR+Tenure=20	4961.22	65.13	4945.25	600.07	0.32%	4961.22	19.40	0.00%
n200p2	IbR+Tenure=20	4663.40	178.70	4429.10	600.08	5.29%	4669.34	104.50	-0.13%
n200p3	IbR	4919.73	272.95	4715.38	600.08	4.33%	4957.67	176.96	-0.77%
n400p1	IbR+Tenure=20	10478.36	1500.26	9305.59	600.18	12.60%	10488.00	359.63	-0.09%
n400p2	IbR+Tenure=20	13085.76	1805.02	6248.32	600.25	109.43%	13108.48	1802.27	-0.17%
n400p3	Tenure=10	11206.16	1892.84	6179.49	600.25	81.34%	12869.30	1800.77	-12.92%

Tabela VI: Abordagens vencedoras vs. modelo exato e GRASP para cada instância

3. APÊNDICE

Declaração de uso de Inteligência Artificial

Foram utilizadas ferramentas de IA para tradução de códigos entre Python e Java e para indentação, dado que alguns discentes tinham maior fluência em Python.

Também foi usada IA para produção de blocos de código auxiliares ao projeto, como por exemplo para criação da função de escrever um csv e para correções nas funções do Tabu (debug)

Por fim, também foi usada IA para auxílio na correção e formatação deste relatório.